Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Proyecto Curricular Ingeniería de Sistemas

Trabajo Primer Corte

Integrantes:

Nelson David Posso Suárez (20212020132)

Julian Cabrera

Edward Julian Garcia Gaitan 20212020136

Juan Cordoba

Docente: Jhon Alejandro Varon Robayo

Asignatura: Mineríá de Datos (020-81)

2026 - I

Índice

1. Introducción **2**

2. Comprensión del problema **2**
2.1. Problema abordado 2
2.2. Decisión que se puede apoyar 2
2.3. Usuarios del análisis 2
2.4. Importancia 2
2.5. Preguntas guía 2

3. Comprensión de los datos **2**
3.1. Fuente 2
3.2. Descripción 3
3.3. Variables del dataset 3
3.4. Tipos de variables, faltantes y tamaño 4
3.5. Preguntas guía 4

4. Limpieza y preparación **4**
4.1. Código aplicado 4
4.2. Justificación de cada decisión 5
4.3. Preguntas guía 5

5. Análisis Exploratorio de Datos (EDA) **5**
5.1. Análisis univariado 5
5.2. Relaciones bivariadas 7
5.3. Matriz de correlación 7
5.4. Análisis multivariado 7
5.5. Conclusión del EDA 7

1. Introducción

Este informe documenta el avance del trabajo de primer corte de minería de datos usando el conjunto `Cancer_Data.csv`. Se presenta lo realizado hasta el momento en el notebook, cubriendo: comprensión del problema, comprensión de los datos, limpieza y preparación.

2. Comprensión del problema

2.1. Problema abordado

Se busca analizar características clínicas medidas en tumores mamarios para diferenciar entre diagnósticos **benignos (B)** y **malignos (M)**, apoyando una clasificación temprana y confiable.

2.2. Decisión que se puede apoyar

Con este análisis se pueden priorizar casos con mayor probabilidad de malignidad para evaluación médica más rápida, apoyo al tamizaje y seguimiento clínico.

2.3. Usuarios del análisis

Este análisis puede ser usado por personal médico (oncología, radiología, medicina general), equipos de apoyo diagnóstico, investigadores biomédicos y gestores hospitalarios.

2.4. Importancia

La detección oportuna impacta directamente el pronóstico y tratamiento del cáncer de mama. Un análisis adecuado puede reducir retrasos y mejorar el uso de recursos clínicos.

2.5. Preguntas guía

- **Tipo de problema:** principalmente predictivo, con apoyo descriptivo en la etapa exploratoria.
- **Variable más importante:** `diagnosis`, al ser la variable objetivo.
- **Riesgo de mala interpretación:** decisiones clínicas erradas, especialmente falsos negativos (clasificar un caso maligno como benigno).

3. Comprensión de los datos

3.1. Fuente

https://www.kaggle.com/datasets/erdemtaha/cancer-data

3.2. Descripción

El dataset contiene mediciones morfológicas de núcleos celulares obtenidas de imágenes de masas mamarias (biopsia por aspiración con aguja fina). El objetivo es distinguir entre tumores benignos y malignos.

3.3. Variables del dataset

Variable	Descripción
`id`	Identificador único del caso/paciente.
`diagnosis`	Diagnóstico (B = Benigno, M = Maligno).
`radius_mean`	Promedio del radio.
`texture_mean`	Promedio de textura (variación de niveles de gris).
`perimeter_mean`	Promedio del perímetro.
`area_mean`	Promedio del área.
`smoothness_mean`	Promedio de suavidad.
`compactness_mean`	Promedio de compacidad.
`concavity_mean`	Promedio de concavidad.
`concave points_mean`	Promedio de puntos cóncavos.
`symmetry_mean`	Promedio de simetría.
`fractal_dimension_mean`	Promedio de dimensión fractal.
`radius_se`	Error estándar del radio.
`texture_se`	Error estándar de textura.
`perimeter_se`	Error estándar del perímetro.
`area_se`	Error estándar del área.
`smoothness_se`	Error estándar de suavidad.
`compactness_se`	Error estándar de compacidad.
`concavity_se`	Error estándar de concavidad.
`concave points_se`	Error estándar de puntos cóncavos.
`symmetry_se`	Error estándar de simetría.
`fractal_dimension_se`	Error estándar de dimensión fractal.
`radius_worst`	Valor peor/máximo del radio.
`texture_worst`	Valor peor/máximo de textura.
`perimeter_worst`	Valor peor/máximo del perímetro.
`area_worst`	Valor peor/máximo del área.
`smoothness_worst`	Valor peor/máximo de suavidad.
`compactness_worst`	Valor peor/máximo de compacidad.
`concavity_worst`	Valor peor/máximo de concavidad.
`concave points_worst`	Valor peor/máximo de puntos cóncavos.
`symmetry_worst`	Valor peor/máximo de simetría.
`fractal_dimension_worst`	Valor peor/máximo de dimensión fractal.

3.4. Tipos de variables, faltantes y tamaño

- Variables categóricas: 1 (`diagnosis`).
- Variables numéricas: 31 (`id` + 30 mediciones clínicas continuas).
- Faltantes detectados inicialmente: una columna extra sin nombre `Unnamed: 32`, completamente vacía.
- Tamaño del dataset tras limpieza: 569 filas y 32 columnas.

3.5. Preguntas guía

- **Variables más relevantes:** medidas de tamaño, forma e irregularidad del tumor (por ejemplo `radius_mean`, `perimeter_mean`, `area_mean`, `radius_worst`, `concave points_worst`).
- **Variables redundantes o inútiles:** pueden existir variables que aportan información similar entre sus versiones `mean`, `se` y `worst`; además `id` no se usa para modelar el fenómeno clínico.
- **Sesgos:** hay más casos benignos que malignos, lo cual implica desbalance de clases.
- **Calidad de datos:** se encontró una columna vacía por formato del archivo y se removió en preparación.

4. Limpieza y preparación

4.1. Código aplicado

```
# Limpieza y preparacion del dataset

df_prep = df.copy()

# 1) Verificacion de valores nulos
print(df_prep.isna().sum().sort_values(ascending=False))
print(f"Total de nulos: {df_prep.isna().sum().sum()}")

# 2) Verificacion de duplicados
print(f"Filas duplicadas completas: {df_prep.duplicated().sum()}")
print(f"Id duplicados: {df_prep['id'].duplicated().sum()}")

# 3) Eliminacion de columna identificadora para analisis/modelado
df_prep = df_prep.drop(columns=["id"])

# 4) Transformacion de la variable objetivo a formato numerico
df_prep["diagnosis_num"] = df_prep["diagnosis"].map({"B": 0, "M":
    1})
```

4.2. Justificación de cada decisión

- **Tratamiento de nulos:** no se imputaron valores porque, tras remover la columna vacía, no hubo nulos en las variables útiles.
- **Eliminación de duplicados:** no se eliminaron filas porque no se detectaron duplicados de filas ni de `id`.
- **Transformaciones:**
  - Se eliminó `id` en el dataset de trabajo porque es un identificador, no una característica clínica.
  - Se creó `diagnosis_num` (B=0, M=1) para facilitar análisis cuantitativos y futuras etapas de modelado.

4.3. Preguntas guía

- **¿Qué pasa si NO limpian los datos?** Se pueden mantener errores de formato, columnas no informativas y estructuras inconsistentes que afecten análisis posteriores.
- **¿Qué decisiones podrían alterar los resultados?** Imputar nulos, eliminar filas/columnas, codificar variables o mantener identificadores puede cambiar el comportamiento de análisis y modelos.
- **¿Están perdiendo información al limpiar?** En este caso no se perdió información clínica relevante: se eliminó una columna vacía y una columna de identificación; se conservó el resto de variables clínicas.

5. Análisis Exploratorio de Datos (EDA)

En esta etapa se realizó un análisis exploratorio de las variables seleccionadas de tipo `mean`, con el objetivo de identificar patrones de distribución, relaciones entre variables y diferencias entre las clases `B` (benigno) y `M` (maligno). Para mantener el análisis enfocado, se excluyeron `radius_mean` y `perimeter_mean` en algunos apartados, debido a su alta relación con `area_mean` y a la redundancia conceptual entre estas variables.

5.1. Análisis univariado

A través de las visualizaciones podemos identificar comportamientos clave en las distribuciones de las variables clínicas.

Al analizar como Analista de Datos los histogramas de `area_mean` y `concavity_mean` (Figura 1), se evidencia una notable diferenciación y poder de separabilidad entre las dos clases. Para ambas variables, las instancias diagnosticadas como **Benignas (B)** se concentran en desviaciones mucho más estrechas y en rangos de valores consistentemente bajos (por ejemplo, `area_mean` inferior a 700-800). Por el contrario, los casos **Malignos (M)** exhiben valores significativamente más altos de área y concavidad, así como una mayor dispersión a lo largo

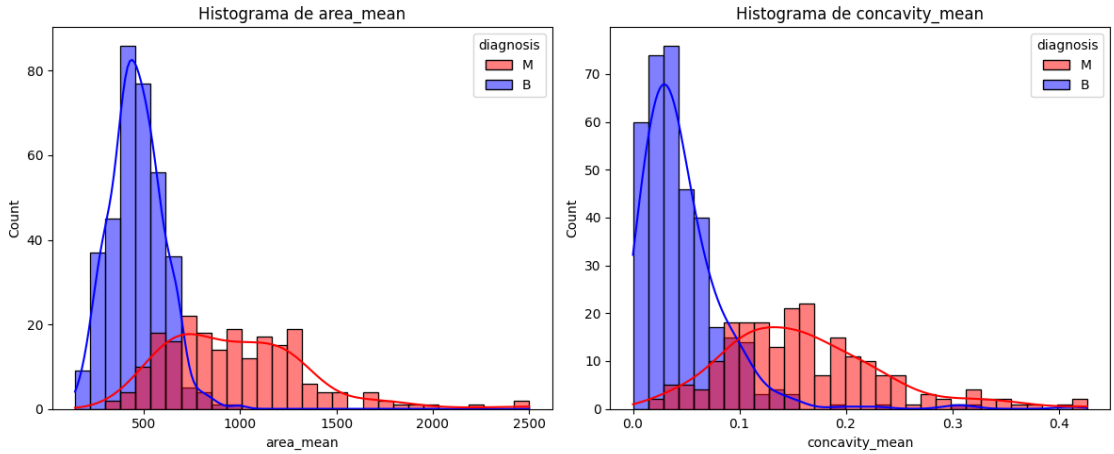

Figura 1: Distribuciones de area_mean y concavity_mean según diagnóstico

de la cola derecha. Esta clara separación visual nos indica que cuando un tejido supera ciertos umbrales críticos en estas métricas, la probabilidad de malignidad escala abruptamente, convirtiendo a `area_mean` y `concavity_mean` en predictores fuertes y tempranos.

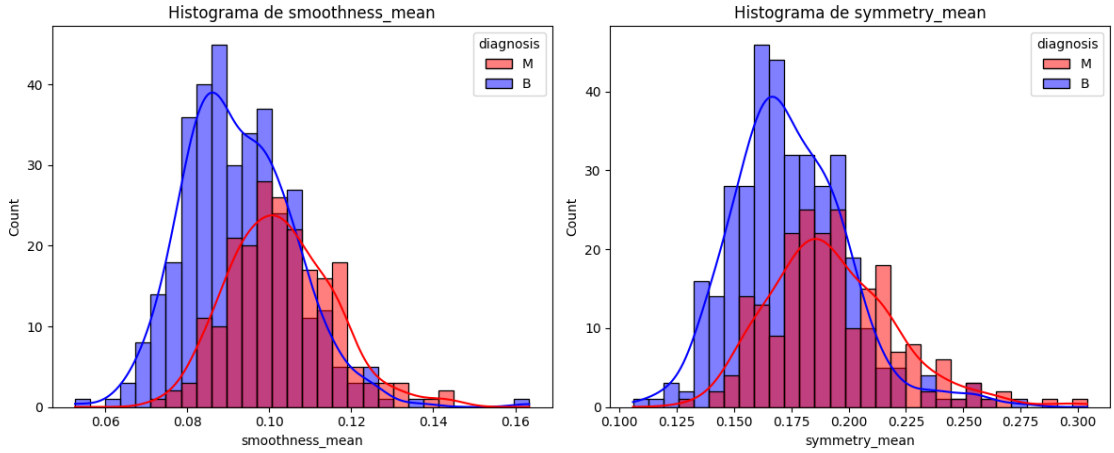

Figura 2: Distribuciones de smoothness_mean y symmetry_mean según diagnóstico

En contraste, el análisis de `smoothness_mean` y `symmetry_mean` (Figura 2) revela un escenario de elevada interdependencia y un marcado entrelazamiento entre las clases. Las curvas de densidad están fuertemente superpuestas («revueltas»), lo que en términos analíticos significa que ninguna de estas dos variables, por sí sola, posee la capacidad de discriminar tajantemente si un tumor es benigno o maligno. Sin embargo, al examinar detalladamente las cumbres de estas frecuencias, sí se percibe una sutil tendencia: los picos de las distribuciones para la clase Maligna están ligeramente desplazados hacia la derecha en comparación con los de la clase Benigna. Esto sugiere que, aunque los valores de suavidad y simetría se compartan ampliamente en gran parte de la muestra, mayores niveles en ambas métricas podrían actuar como factores de riesgo complementarios que sólo tendrán auténtico valor predictivo cuando interactúen multivariablemente con predictores principales como el área o la concavidad.

Los boxplots refuerzan esta observación. Variables como `concavity_mean` y `concave points_mean` muestran una diferenciación más clara entre clases, lo que sugiere mayor capacidad discriminante. Por otro lado, variables como `texture_mean`, `smoothness_mean`, `symmetry_mean` y `fractal_dimension_mean` presentan mayor solapamiento, por lo que su poder de separación individual parece menor.

5.2. Relaciones bivariadas

Los scatterplots construidos usando `area_mean` como referencia muestran relaciones positivas con varias variables del conjunto. En particular, se observa que al aumentar `area_mean` también tienden a aumentar variables como `concavity_mean`, `concave points_mean` y `compactness_mean`. Esto sugiere que los tumores de mayor tamaño suelen presentar también formas más irregulares.

Además, los casos malignos tienden a concentrarse en regiones de valores más altos, mientras que los benignos permanecen en rangos más bajos. Esto indica que las variables morfológicas no solo describen el tamaño del tumor, sino también características asociadas con su grado de irregularidad.

5.3. Matriz de correlación

La matriz de correlación evidencia relaciones lineales importantes entre varias variables. Se aprecia una fuerte asociación entre las variables relacionadas con tamaño, como `area_mean`, `radius_mean` y `perimeter_mean`, lo cual confirma que contienen información parcialmente redundante. También se observa una relación destacada entre `concavity_mean` y `concave points_mean`, lo que indica que ambas capturan aspectos similares de la morfología del tumor.

En cambio, variables como `fractal_dimension_mean` y `symmetry_mean` muestran correlaciones más débiles con el resto, por lo que aportan información complementaria pero menos dominante dentro del conjunto.

5.4. Análisis multivariado

El `pairplot` permite observar simultáneamente la relación entre las variables seleccionadas y el diagnóstico. Este gráfico confirma que algunas variables, especialmente `area_mean`, `concavity_mean` y `concave points_mean`, ayudan a separar parcialmente las clases `B` y `M`. Sin embargo, también se aprecia solapamiento entre observaciones, lo que indica que no existe una separación perfecta usando una sola variable.

En conjunto, el análisis multivariado sugiere que la combinación de varias características morfológicas puede mejorar la capacidad de discriminación entre tumores benignos y malignos.

5.5. Conclusión del EDA

El análisis exploratorio muestra que las variables más relevantes para diferenciar entre diagnóstico benigno y maligno son aquellas asociadas al tamaño y a la irregularidad de la

masa, en especial `area_mean`, `concavity_mean` y `concave points_mean`. También se confirma la existencia de correlaciones fuertes entre algunas variables, lo que sugiere redundancia parcial en el conjunto de datos.

Por esta razón, en etapas posteriores del proyecto se recomienda:

- priorizar variables con mayor capacidad de separación entre clases;
- revisar la multicolinealidad entre variables altamente correlacionadas;
- considerar técnicas de selección de características;
- tener en cuenta el desbalance entre clases al construir modelos.