Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Proyecto Curricular Ingeniería de Sistemas

Trabajo Primer Corte

Integrantes:

Nelson David Posso Suárez (20212020132)

Julian Cabrera

Edward Garcia

Juan Cordoba

Docente: Jhon Alejandro Varon Robayo

Asignatura: Mineríá de Datos (020-81)

2026 - I

Índice

1. Introducción **2**

2. Comprensión del problema **2**
2.1. Problema abordado 2
2.2. Decisión que se puede apoyar 2
2.3. Usuarios del análisis 2
2.4. Importancia 2
2.5. Preguntas guía 2

3. Comprensión de los datos **2**
3.1. Fuente 2
3.2. Descripción 3
3.3. Variables del dataset 3
3.4. Tipos de variables, faltantes y tamaño 4
3.5. Preguntas guía 4

4. Limpieza y preparación **4**
4.1. Código aplicado 4
4.2. Justificación de cada decisión 5
4.3. Preguntas guía 5

5. EDA – Análisis Exploratorio **5**

1. Introducción

Este informe documenta el avance del trabajo de primer corte de minería de datos usando el conjunto `Cancer_Data.csv`. Se presenta lo realizado hasta el momento en el notebook, cubriendo: comprensión del problema, comprensión de los datos, limpieza y preparación.

2. Comprensión del problema

2.1. Problema abordado

Se busca analizar características clínicas medidas en tumores mamarios para diferenciar entre diagnósticos **benignos (B)** y **malignos (M)**, apoyando una clasificación temprana y confiable.

2.2. Decisión que se puede apoyar

Con este análisis se pueden priorizar casos con mayor probabilidad de malignidad para evaluación médica más rápida, apoyo al tamizaje y seguimiento clínico.

2.3. Usuarios del análisis

Este análisis puede ser usado por personal médico (oncología, radiología, medicina general), equipos de apoyo diagnóstico, investigadores biomédicos y gestores hospitalarios.

2.4. Importancia

La detección oportuna impacta directamente el pronóstico y tratamiento del cáncer de mama. Un análisis adecuado puede reducir retrasos y mejorar el uso de recursos clínicos.

2.5. Preguntas guía

- **Tipo de problema:** principalmente predictivo, con apoyo descriptivo en la etapa exploratoria.
- **Variable más importante:** `diagnosis`, al ser la variable objetivo.
- **Riesgo de mala interpretación:** decisiones clínicas erradas, especialmente falsos negativos (clasificar un caso maligno como benigno).

3. Comprensión de los datos

3.1. Fuente

https://www.kaggle.com/datasets/erdemtaha/cancer-data

3.2. Descripción

El dataset contiene mediciones morfológicas de núcleos celulares obtenidas de imágenes de masas mamarias (biopsia por aspiración con aguja fina). El objetivo es distinguir entre tumores benignos y malignos.

3.3. Variables del dataset

Variable	Descripción
`id`	Identificador único del caso/paciente.
`diagnosis`	Diagnóstico (B = Benigno, M = Maligno).
`radius_mean`	Promedio del radio.
`texture_mean`	Promedio de textura (variación de niveles de gris).
`perimeter_mean`	Promedio del perímetro.
`area_mean`	Promedio del área.
`smoothness_mean`	Promedio de suavidad.
`compactness_mean`	Promedio de compacidad.
`concavity_mean`	Promedio de concavidad.
`concave points_mean`	Promedio de puntos cóncavos.
`symmetry_mean`	Promedio de simetría.
`fractal_dimension_mean`	Promedio de dimensión fractal.
`radius_se`	Error estándar del radio.
`texture_se`	Error estándar de textura.
`perimeter_se`	Error estándar del perímetro.
`area_se`	Error estándar del área.
`smoothness_se`	Error estándar de suavidad.
`compactness_se`	Error estándar de compacidad.
`concavity_se`	Error estándar de concavidad.
`concave points_se`	Error estándar de puntos cóncavos.
`symmetry_se`	Error estándar de simetría.
`fractal_dimension_se`	Error estándar de dimensión fractal.
`radius_worst`	Valor peor/máximo del radio.
`texture_worst`	Valor peor/máximo de textura.
`perimeter_worst`	Valor peor/máximo del perímetro.
`area_worst`	Valor peor/máximo del área.
`smoothness_worst`	Valor peor/máximo de suavidad.
`compactness_worst`	Valor peor/máximo de compacidad.
`concavity_worst`	Valor peor/máximo de concavidad.
`concave points_worst`	Valor peor/máximo de puntos cóncavos.
`symmetry_worst`	Valor peor/máximo de simetría.
`fractal_dimension_worst`	Valor peor/máximo de dimensión fractal.

3.4. Tipos de variables, faltantes y tamaño

- Variables categóricas: 1 (`diagnosis`).
- Variables numéricas: 31 (`id` + 30 mediciones clínicas continuas).
- Faltantes detectados inicialmente: una columna extra sin nombre `Unnamed: 32`, completamente vacía.
- Tamaño del dataset tras limpieza: 569 filas y 32 columnas.

3.5. Preguntas guía

- **Variables más relevantes:** medidas de tamaño, forma e irregularidad del tumor (por ejemplo `radius_mean`, `perimeter_mean`, `area_mean`, `radius_worst`, `concave points_worst`).
- **Variables redundantes o inútiles:** pueden existir variables que aportan información similar entre sus versiones `mean`, `se` y `worst`; además `id` no se usa para modelar el fenómeno clínico.
- **Sesgos:** hay más casos benignos que malignos, lo cual implica desbalance de clases.
- **Calidad de datos:** se encontró una columna vacía por formato del archivo y se removió en preparación.

4. Limpieza y preparación

4.1. Código aplicado

```
# Limpieza y preparacion del dataset

df_prep = df.copy()

# 1) Verificacion de valores nulos
print(df_prep.isna().sum().sort_values(ascending=False))
print(f"Total de nulos: {df_prep.isna().sum().sum()}")

# 2) Verificacion de duplicados
print(f"Filas duplicadas completas: {df_prep.duplicated().sum()}")
print(f"Id duplicados: {df_prep['id'].duplicated().sum()}")

# 3) Eliminacion de columna identificadora para analisis/modelado
df_prep = df_prep.drop(columns=["id"])

# 4) Transformacion de la variable objetivo a formato numerico
df_prep["diagnosis_num"] = df_prep["diagnosis"].map({"B": 0, "M":
    1})
```

4.2. Justificación de cada decisión

- **Tratamiento de nulos:** no se imputaron valores porque, tras remover la columna vacía, no hubo nulos en las variables útiles.
- **Eliminación de duplicados:** no se eliminaron filas porque no se detectaron duplicados de filas ni de `id`.
- **Transformaciones:**
  - Se eliminó `id` en el dataset de trabajo porque es un identificador, no una característica clínica.
  - Se creó `diagnosis_num` (B=0, M=1) para facilitar análisis cuantitativos y futuras etapas de modelado.

4.3. Preguntas guía

- **¿Qué pasa si NO limpian los datos?** Se pueden mantener errores de formato, columnas no informativas y estructuras inconsistentes que afecten análisis posteriores.
- **¿Qué decisiones podrían alterar los resultados?** Imputar nulos, eliminar filas/columnas, codificar variables o mantener identificadores puede cambiar el comportamiento de análisis y modelos.
- **¿Están perdiendo información al limpiar?** En este caso no se perdió información clínica relevante: se eliminó una columna vacía y una columna de identificación; se conservó el resto de variables clínicas.

5. EDA – Análisis Exploratorio

Falta