Trabajo de Primer Corte:

Minería de Datos – Análisis Exploratorio del Conjunto de Datos de Cáncer

Integrantes:

Nelson David Posso Suárez - 20212020132

Julian David Cabrera Barragán - 20212020xxx

Edward Julian García Gaitán - 20212020136

Juan David Córdoba Aguirre - 20211020097

Docente: Jhon Alejandro Varón Robayo

Asignatura: Minería de Datos (020-81)

Semestre: 2026-1

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Proyecto Curricular Ingeniería de Sistemas

Bogotá D.C.

Índice

Introducción **2**

Comprensión del problema **3**

Problema abordado 3

Decisión que se puede apoyar 3

Usuarios del análisis 3

Importancia 3

Preguntas guía 3

Comprensión de los datos **4**

Fuente 4

Descripción 4

Variables del dataset 4

Tipos de variables, faltantes y tamaño 5

Preguntas guía 5

Limpieza y preparación **7**

Código aplicado 7

Justificación de cada decisión 7

Preguntas guía 8

Análisis Exploratorio de Datos (EDA) **9**

Análisis univariado 9

Relaciones bivariadas 9

Matriz de correlación 10

Análisis multivariado 10

Conclusión del EDA 10

Introducción

Este informe documenta el avance del trabajo de primer corte de minería de datos usando el conjunto `Cancer_Data.csv`. Se presenta lo realizado hasta el momento en el notebook, cubriendo: comprensión del problema, comprensión de los datos, limpieza y preparación.

Comprensión del problema

Problema abordado

Se busca analizar características clínicas medidas en tumores mamarios para diferenciar entre diagnósticos **benignos (B)** y **malignos (M)**, apoyando una clasificación temprana y confiable.

Decisión que se puede apoyar

Con este análisis se pueden priorizar casos con mayor probabilidad de malignidad para evaluación médica más rápida, apoyo al tamizaje y seguimiento clínico.

Usuarios del análisis

Este análisis puede ser usado por personal médico (oncología, radiología, medicina general), equipos de apoyo diagnóstico, investigadores biomédicos y gestores hospitalarios.

Importancia

La detección oportuna impacta directamente el pronóstico y tratamiento del cáncer de mama. Un análisis adecuado puede reducir retrasos y mejorar el uso de recursos clínicos.

Preguntas guía

- **Tipo de problema:** principalmente predictivo, con apoyo descriptivo en la etapa exploratoria.
- **Variable más importante:** `diagnosis`, al ser la variable objetivo.
- **Riesgo de mala interpretación:** decisiones clínicas erradas, especialmente falsos negativos (clasificar un caso maligno como benigno).

Comprensión de los datos

Fuente

https://www.kaggle.com/datasets/erdemtaha/cancer-data

Descripción

El dataset contiene mediciones morfológicas de núcleos celulares obtenidas de imágenes de masas mamarias (biopsia por aspiración con aguja fina). El objetivo es distinguir entre tumores benignos y malignos.

Variables del dataset

Variable	Descripción
`id`	Identificador único del caso/paciente.
`diagnosis`	Diagnóstico (B = Benigno, M = Maligno).
`radius_mean`	Promedio del radio.
`texture_mean`	Promedio de textura (variación de niveles de gris).
`perimeter_mean`	Promedio del perímetro.
`area_mean`	Promedio del área.
`smoothness_mean`	Promedio de suavidad.
`compactness_mean`	Promedio de compacidad.
`concavity_mean`	Promedio de concavidad.
`concave points_mean`	Promedio de puntos cóncavos.
`symmetry_mean`	Promedio de simetría.
`fractal_dimension_mean`	Promedio de dimensión fractal.
`radius_se`	Error estándar del radio.
`texture_se`	Error estándar de textura.
`perimeter_se`	Error estándar del perímetro.
`area_se`	Error estándar del área.
`smoothness_se`	Error estándar de suavidad.

Variable	Descripción
`compactness_se`	Error estándar de compacidad.
`concavity_se`	Error estándar de concavidad.
`concave points_se`	Error estándar de puntos cóncavos.
`symmetry_se`	Error estándar de simetría.
`fractal_dimension_se`	Error estándar de dimensión fractal.
`radius_worst`	Valor peor/máximo del radio.
`texture_worst`	Valor peor/máximo de textura.
`perimeter_worst`	Valor peor/máximo del perímetro.
`area_worst`	Valor peor/máximo del área.
`smoothness_worst`	Valor peor/máximo de suavidad.
`compactness_worst`	Valor peor/máximo de compacidad.
`concavity_worst`	Valor peor/máximo de concavidad.
`concave points_worst`	Valor peor/máximo de puntos cóncavos.
`symmetry_worst`	Valor peor/máximo de simetría.
`fractal_dimension_worst`	Valor peor/máximo de dimensión fractal.

Tipos de variables, faltantes y tamaño

- Variables categóricas: 1 (`diagnosis`).
- Variables numéricas: 31 (`id` + 30 mediciones clínicas continuas).
- Faltantes detectados inicialmente: una columna extra sin nombre `Unnamed: 32`, completamente vacía.
- Tamaño del dataset tras limpieza: 569 filas y 32 columnas.

Preguntas guía

- **Variables más relevantes:** medidas de tamaño, forma e irregularidad del tumor (por ejemplo `radius_mean`, `perimeter_mean`, `area_mean`, `radius_worst`, `concave points_worst`).

- **Variables redundantes o inútiles:** pueden existir variables que aportan información similar entre sus versiones `mean`, `se` y `worst`; además `id` no se usa para modelar el fenómeno clínico.
- **Sesgos:** hay más casos benignos que malignos, lo cual implica desbalance de clases.
- **Calidad de datos:** se encontró una columna vacía por formato del archivo y se removió en preparación.

Limpieza y preparación

Código aplicado

```
# Limpieza y preparacion del dataset

df_prep = df.copy()

# 1) Verificacion de valores nulos
print(df_prep.isna().sum().sort_values(ascending=False))
print(f"Total de nulos: {df_prep.isna().sum().sum()}")

# 2) Verificacion de duplicados
print(f"Filas duplicadas completas: {df_prep.duplicated().sum()}")
print(f"Id duplicados: {df_prep['id'].duplicated().sum()}")

# 3) Eliminacion de columna identificadora para analisis/modelado
df_prep = df_prep.drop(columns=["id"])

# 4) Transformacion de la variable objetivo a formato numerico
df_prep["diagnosis_num"] = df_prep["diagnosis"].map({"B": 0, "M": 1})
```

Justificación de cada decisión

- **Tratamiento de nulos:** no se imputaron valores porque, tras remover la columna vacía, no hubo nulos en las variables útiles.
- **Eliminación de duplicados:** no se eliminaron filas porque no se detectaron duplicados de filas ni de `id`.
- **Transformaciones:**
  - Se eliminó `id` en el dataset de trabajo porque es un identificador, no una característica clínica.

- Se creó `diagnosis_num` (B=0, M=1) para facilitar análisis cuantitativos y futuras etapas de modelado.

Preguntas guía

- **¿Qué pasa si NO limpian los datos?** Se pueden mantener errores de formato, columnas no informativas y estructuras inconsistentes que afecten análisis posteriores.
- **¿Qué decisiones podrían alterar los resultados?** Imputar nulos, eliminar filas/columnas, codificar variables o mantener identificadores puede cambiar el comportamiento de análisis y modelos.
- **¿Están perdiendo información al limpiar?** En este caso no se perdió información clínica relevante: se eliminó una columna vacía y una columna de identificación; se conservó el resto de variables clínicas.

Análisis Exploratorio de Datos (EDA)

En esta etapa se realizó un análisis exploratorio de las variables seleccionadas de tipo `mean`, con el objetivo de identificar patrones de distribución, relaciones entre variables y diferencias entre las clases `B` (benigno) y `M` (maligno). Para mantener el análisis enfocado, se excluyeron `radius_mean` y `perimeter_mean` en algunos apartados, debido a su alta relación con `area_mean` y a la redundancia conceptual entre estas variables.

Análisis univariado

Los histogramas muestran que varias variables presentan distribuciones asimétricas y una separación visible entre los diagnósticos benigno y maligno. En general, los casos malignos tienden a concentrarse en valores más altos de variables relacionadas con tamaño e irregularidad, especialmente `area_mean`, `concavity_mean` y `concave points_mean`. En contraste, los casos benignos se agrupan más hacia valores bajos y con menor dispersión.

Los boxplots refuerzan esta observación. Variables como `concavity_mean` y `concave points_mean` muestran una diferenciación más clara entre clases, lo que sugiere mayor capacidad discriminante. Por otro lado, variables como `texture_mean`, `smoothness_mean`, `symmetry_mean` y `fractal_dimension_mean` presentan mayor solapamiento, por lo que su poder de separación individual parece menor.

Relaciones bivariadas

Los scatterplots construidos usando `area_mean` como referencia muestran relaciones positivas con varias variables del conjunto. En particular, se observa que al aumentar `area_mean` también tienden a aumentar variables como `concavity_mean`, `concave points_mean` y `compactness_mean`. Esto sugiere que los tumores de mayor tamaño suelen presentar también formas más irregulares.

Además, los casos malignos tienden a concentrarse en regiones de valores más altos, mientras que los benignos permanecen en rangos más bajos. Esto indica que las variables morfológicas no solo describen el tamaño del tumor, sino también características asociadas con su grado de irregularidad.

Matriz de correlación

La matriz de correlación evidencia relaciones lineales importantes entre varias variables. Se aprecia una fuerte asociación entre las variables relacionadas con tamaño, como `area_mean`, `radius_mean` y `perimeter_mean`, lo cual confirma que contienen información parcialmente redundante. También se observa una relación destacada entre `concavity_mean` y `concave points_mean`, lo que indica que ambas capturan aspectos similares de la morfología del tumor.

En cambio, variables como `fractal_dimension_mean` y `symmetry_mean` muestran correlaciones más débiles con el resto, por lo que aportan información complementaria pero menos dominante dentro del conjunto.

Análisis multivariado

El `pairplot` permite observar simultáneamente la relación entre las variables seleccionadas y el diagnóstico. Este gráfico confirma que algunas variables, especialmente `area_mean`, `concavity_mean` y `concave points_mean`, ayudan a separar parcialmente las clases `B` y `M`. Sin embargo, también se aprecia solapamiento entre observaciones, lo que indica que no existe una separación perfecta usando una sola variable.

En conjunto, el análisis multivariado sugiere que la combinación de varias características morfológicas puede mejorar la capacidad de discriminación entre tumores benignos y malignos.

Conclusión del EDA

El análisis exploratorio muestra que las variables más relevantes para diferenciar entre diagnóstico benigno y maligno son aquellas asociadas al tamaño y a la irregularidad de la masa, en especial `area_mean`, `concavity_mean` and `concave points_mean`. También se confirma la existencia de correlaciones fuertes entre algunas variables, lo que sugiere redundancia parcial en el conjunto de datos.

Por esta razón, en etapas posteriores del proyecto se recomienda:

- priorizar variables con mayor capacidad de separación entre clases;

- revisar la multicolinealidad entre variables altamente correlacionadas;
- considerar técnicas de selección de características;
- tener en cuenta el desbalance entre clases al construir modelos.