Trabajo de Primer Corte:

Minería de Datos – Análisis Exploratorio del Conjunto de Datos de Cáncer

Integrantes:

Nelson David Posso Suárez - 20212020132

Julian David Cabrera Barragán - 20212020160

Edward Julian García Gaitán - 20212020136

Juan David Córdoba Aguirre - 20211020097

Docente: Jhon Alejandro Varón Robayo

Asignatura: Minería de Datos (020-81)

Semestre: 2026-1

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Proyecto Curricular Ingeniería de Sistemas

Bogotá D.C.

Índice

Introducción **3**

Comprensión del problema **4**

Problema abordado 4

Decisión que se puede apoyar 4

Usuarios del análisis 4

Importancia 4

Preguntas guía 4

Comprensión de los datos **5**

Fuente 5

Descripción 5

Variables del dataset 5

Tipos de variables, faltantes y tamaño 6

Preguntas guía 6

Limpieza y preparación **8**

Código aplicado 8

Justificación de cada decisión 8

Preguntas guía 9

Análisis Exploratorio de Datos (EDA) **10**

Descripción del dataset 10

Comportamiento de las Variables por Diagnóstico 11

Área media 11

Concavidad y Puntos Cóncavos 12

Compacidad media 13

Textura media 14

Suavidad y Simetría 14

Relaciones entre Variables 15

Matriz de correlación 15
Dispersión: área vs. variables de forma 16
Visión global: gráfico de pares 17
Resumen y Conclusiones 18
Capacidad discriminativa por variable 18
Hallazgos principales 18
Nota clínica 19
Glosario 19
Conclusión del EDA 20
Interpretación 20
Patrones encontrados 20
Variables de mayor influencia 21
Conclusiones y toma de decisiones 21
Siguientes pasos 21

Introducción

Este informe documenta el avance del trabajo de primer corte de minería de datos usando el conjunto `Cancer_Data.csv`. Se presenta lo realizado hasta el momento en el notebook, cubriendo: comprensión del problema, comprensión de los datos, limpieza y preparación.

Comprensión del problema

Problema abordado

Se busca analizar características clínicas medidas en tumores mamarios para diferenciar entre diagnósticos **benignos (B)** y **malignos (M)**, apoyando una clasificación temprana y confiable.

Decisión que se puede apoyar

Con este análisis se pueden priorizar casos con mayor probabilidad de malignidad para evaluación médica más rápida, apoyo al tamizaje y seguimiento clínico.

Usuarios del análisis

Este análisis puede ser usado por personal médico (oncología, radiología, medicina general), equipos de apoyo diagnóstico, investigadores biomédicos y gestores hospitalarios.

Importancia

La detección oportuna impacta directamente el pronóstico y tratamiento del cáncer de mama. Un análisis adecuado puede reducir retrasos y mejorar el uso de recursos clínicos.

Preguntas guía

- **Tipo de problema:** principalmente predictivo, con apoyo descriptivo en la etapa exploratoria.
- **Variable más importante:** `diagnosis`, al ser la variable objetivo.
- **Riesgo de mala interpretación:** decisiones clínicas erradas, especialmente falsos negativos (clasificar un caso maligno como benigno).

Comprensión de los datos

Fuente

https://www.kaggle.com/datasets/erdemtaha/cancer-data

Descripción

El dataset contiene mediciones morfológicas de núcleos celulares obtenidas de imágenes de masas mamarias (biopsia por aspiración con aguja fina). El objetivo es distinguir entre tumores benignos y malignos.

Variables del dataset

Variable	Descripción
`id`	Identificador único del caso/paciente.
`diagnosis`	Diagnóstico (B = Benigno, M = Maligno).
`radius_mean`	Promedio del radio.
`texture_mean`	Promedio de textura (variación de niveles de gris).
`perimeter_mean`	Promedio del perímetro.
`area_mean`	Promedio del área.
`smoothness_mean`	Promedio de suavidad.
`compactness_mean`	Promedio de compacidad.
`concavity_mean`	Promedio de concavidad.
`concave points_mean`	Promedio de puntos cóncavos.
`symmetry_mean`	Promedio de simetría.
`fractal_dimension_mean`	Promedio de dimensión fractal.
`radius_se`	Error estándar del radio.
`texture_se`	Error estándar de textura.
`perimeter_se`	Error estándar del perímetro.
`area_se`	Error estándar del área.
`smoothness_se`	Error estándar de suavidad.

Variable	Descripción
`compactness_se`	Error estándar de compacidad.
`concavity_se`	Error estándar de concavidad.
`concave points_se`	Error estándar de puntos cóncavos.
`symmetry_se`	Error estándar de simetría.
`fractal_dimension_se`	Error estándar de dimensión fractal.
`radius_worst`	Valor peor/máximo del radio.
`texture_worst`	Valor peor/máximo de textura.
`perimeter_worst`	Valor peor/máximo del perímetro.
`area_worst`	Valor peor/máximo del área.
`smoothness_worst`	Valor peor/máximo de suavidad.
`compactness_worst`	Valor peor/máximo de compacidad.
`concavity_worst`	Valor peor/máximo de concavidad.
`concave points_worst`	Valor peor/máximo de puntos cóncavos.
`symmetry_worst`	Valor peor/máximo de simetría.
`fractal_dimension_worst`	Valor peor/máximo de dimensión fractal.

Tipos de variables, faltantes y tamaño

- Variables categóricas: 1 (`diagnosis`).
- Variables numéricas: 31 (`id` + 30 mediciones clínicas continuas).
- Faltantes detectados inicialmente: una columna extra sin nombre `Unnamed: 32`, completamente vacía.
- Tamaño del dataset tras limpieza: 569 filas y 32 columnas.

Preguntas guía

- **Variables más relevantes:** medidas de tamaño, forma e irregularidad del tumor (por ejemplo `radius_mean`, `perimeter_mean`, `area_mean`, `radius_worst`, `concave points_worst`).

- **Variables redundantes o inútiles:** pueden existir variables que aportan información similar entre sus versiones `mean`, `se` y `worst`; además `id` no se usa para modelar el fenómeno clínico.
- **Sesgos:** hay más casos benignos que malignos, lo cual implica desbalance de clases.
- **Calidad de datos:** se encontró una columna vacía por formato del archivo y se removió en preparación.

Limpieza y preparación

Código aplicado

```
# Limpieza y preparacion del dataset

df_prep = df.copy()

# 1) Verificacion de valores nulos
print(df_prep.isna().sum().sort_values(ascending=False))
print(f"Total de nulos: {df_prep.isna().sum().sum()}")

# 2) Verificacion de duplicados
print(f"Filas duplicadas completas: {df_prep.duplicated().sum()}")
print(f"Id duplicados: {df_prep['id'].duplicated().sum()}")

# 3) Eliminacion de columna identificadora para analisis/modelado
df_prep = df_prep.drop(columns=["id"])

# 4) Transformacion de la variable objetivo a formato numerico
df_prep["diagnosis_num"] = df_prep["diagnosis"].map({"B": 0, "M": 1})
```

Justificación de cada decisión

- **Tratamiento de nulos:** no se imputaron valores porque, tras remover la columna vacía, no hubo nulos en las variables útiles.
- **Eliminación de duplicados:** no se eliminaron filas porque no se detectaron duplicados de filas ni de `id`.
- **Transformaciones:**
  - Se eliminó `id` en el dataset de trabajo porque es un identificador, no una característica clínica.

- Se creó `diagnosis_num` (B=0, M=1) para facilitar análisis cuantitativos y futuras etapas de modelado.

Preguntas guía

- **¿Qué pasa si NO limpian los datos?** Se pueden mantener errores de formato, columnas no informativas y estructuras inconsistentes que afecten análisis posteriores.
- **¿Qué decisiones podrían alterar los resultados?** Imputar nulos, eliminar filas/columnas, codificar variables o mantener identificadores puede cambiar el comportamiento de análisis y modelos.
- **¿Están perdiendo información al limpiar?** En este caso no se perdió información clínica relevante: se eliminó una columna vacía y una columna de identificación; se conservó el resto de variables clínicas.

Análisis Exploratorio de Datos (EDA)

Este informe presenta los resultados del análisis exploratorio del conjunto de datos *Breast Cancer Wisconsin (Diagnostic)*, que contiene mediciones morfológicas extraídas de imágenes digitalizadas de aspirados con aguja fina (FNA) de masas mamarias. El objetivo es ofrecer al personal médico una comprensión clara del comportamiento de las variables morfológicas del tejido mamario según el tipo de diagnóstico: **Maligno (M)** y **Benigno (B)**.

Descripción del dataset

Cada registro corresponde a una muestra de tejido mamario e incluye 30 variables numéricas agrupadas en tres tipos:

- **Valores medios** (`_mean`): promedio de cada característica en la muestra.
- **Error estándar** (`_se`): variabilidad de cada medición dentro de la muestra.
- **Valores extremos** (`_worst`): media de los tres valores más altos de cada característica.

El análisis que sigue se centra en las variables `_mean`, que representan el comportamiento general de cada muestra. Las características evaluadas son: radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal.

Nota sobre las gráficas: en las Figuras 2 y 6 la codificación de color es inversa respecto al resto del informe (M = rojo, B = azul). El análisis interpretativo es consistente en todos los casos.

Comportamiento de las Variables por Diagnóstico

Área media

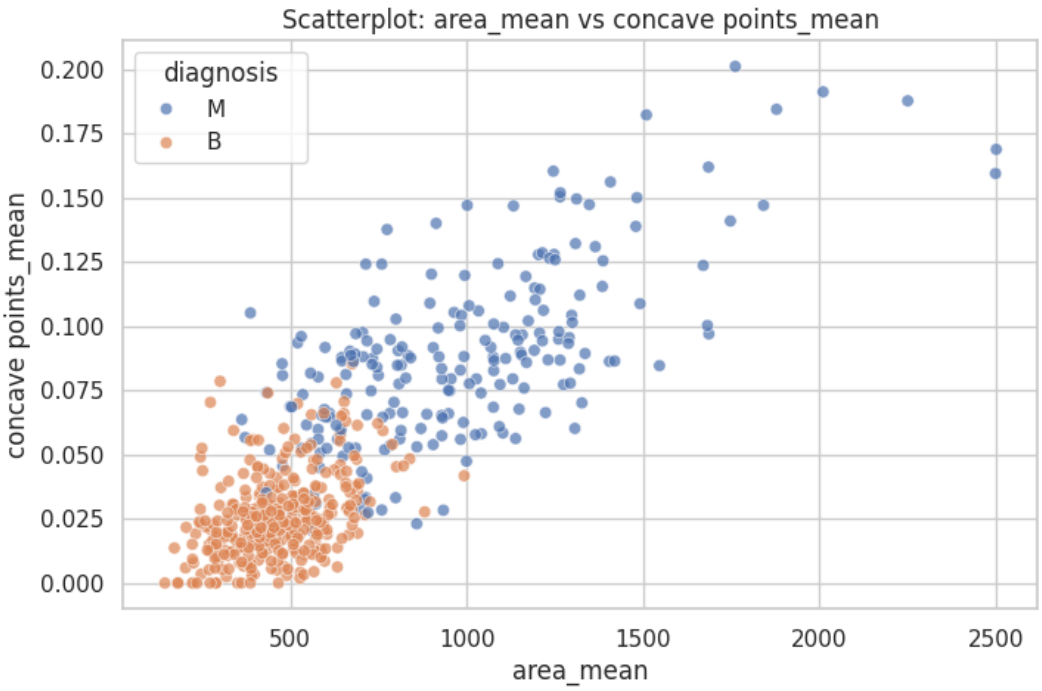

Figura 1: Histograma y boxplot de `area_mean` según diagnóstico.

El área media del núcleo celular es la variable con mayor diferencia observable entre grupos. Las muestras malignas presentan núcleos aproximadamente el doble de grandes que las benignas, con una mediana cercana a 900–1000 unidades frente a valores por debajo de 500 en los casos benignos. La distribución maligna es además mucho más amplia, con valores que alcanzan 2 500 unidades. Un núcleo celular de mayor tamaño es uno de los hallazgos morfológicos clásicamente asociados a malignidad, por lo que esta variable tiene alto valor discriminativo.

Concavidad y Puntos Cóncavos

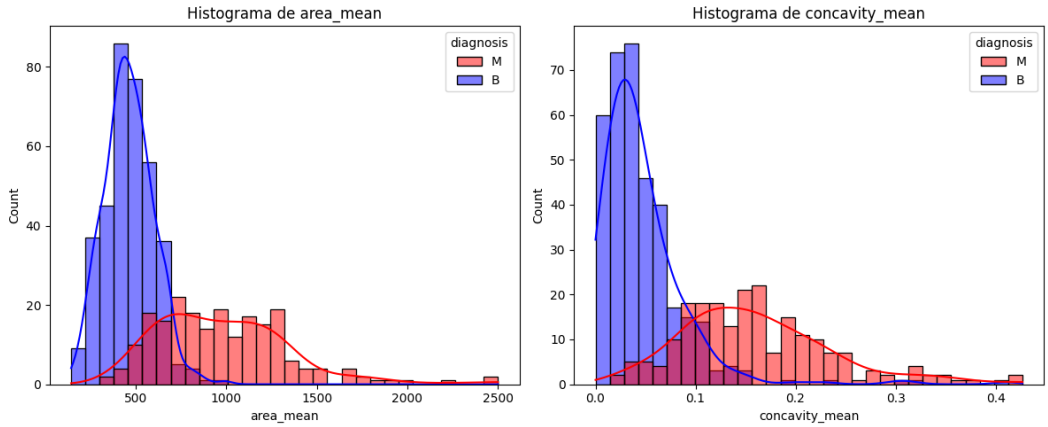

Figura 2: Histogramas de `area_mean` y `concavity_mean` según diagnóstico.

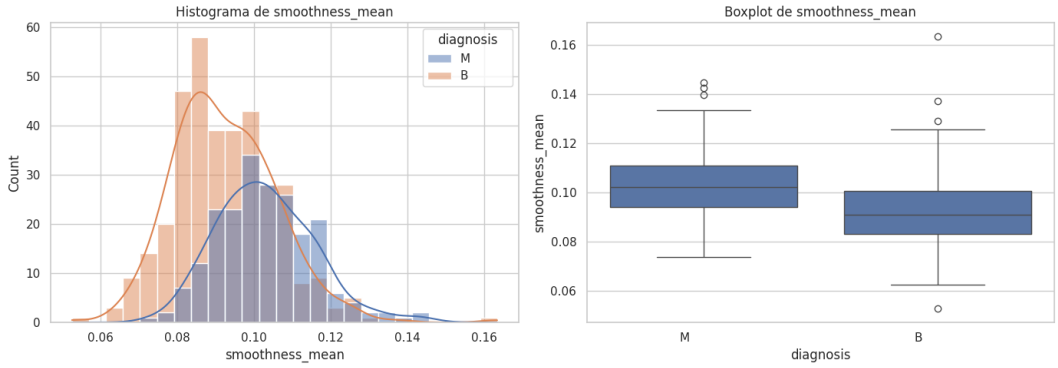

Figura 3: Histograma y boxplot de `concave points_mean` según diagnóstico.

La concavidad media y los puntos cóncavos son las variables con mayor separación entre grupos. La gran mayoría de las muestras benignas presentan valores muy bajos o cercanos a cero en ambas variables, mientras que las malignas se distribuyen ampliamente hacia valores superiores.

El histograma de concavidad (Figura 2) confirma que los casos benignos se concentran casi exclusivamente en el rango 0–0.05, mientras que los malignos presentan distribución bimodal con presencia frecuente de concavidades pronunciadas. En el boxplot de puntos cóncavos (Figura 3), la separación es aún más nítida: la mediana de los

casos malignos (aproximadamente 0.085) más que triplica la de los benignos (cercana a 0.02).

La presencia de concavidades pronunciadas en el contorno nuclear es coherente con el criterio histológico de *pleomorfismo nuclear*, característico de células malignas. Estas dos variables constituyen los discriminadores más potentes del dataset.

Compacidad media

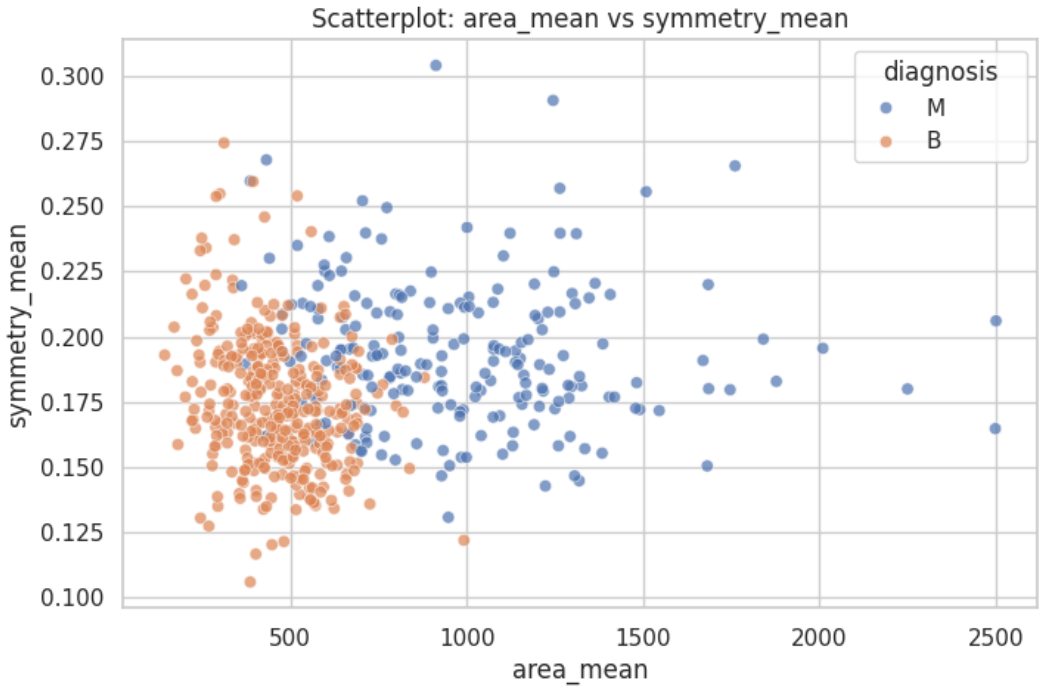

Figura 4: Histograma y boxplot de `compactness_mean` según diagnóstico.

La compacidad, que relaciona el perímetro al cuadrado con el área celular, muestra una separación clara entre grupos. Los tumores malignos presentan valores marcadamente más altos, con distribución amplia y sesgada a la derecha, mientras que los benignos se concentran en valores bajos (0.05–0.10). Una compacidad elevada refleja núcleos con formas irregulares, hallazgo histológico frecuentemente asociado a malignidad.

Textura media

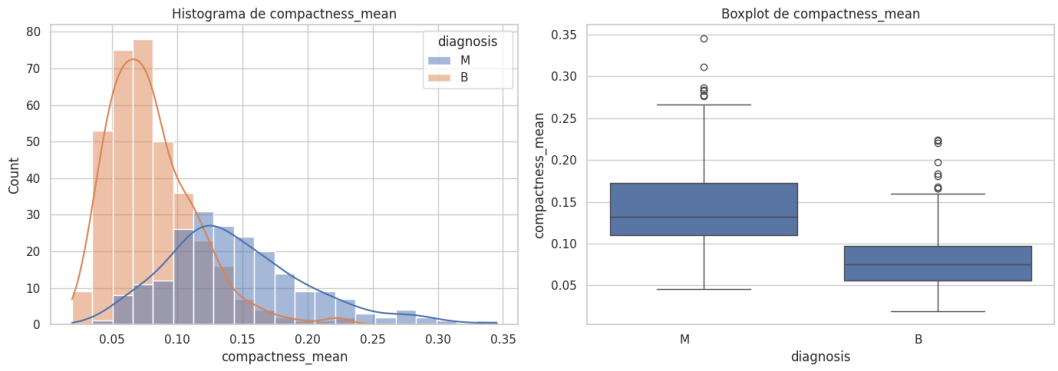

Figura 5: Histograma y boxplot de `texture_mean` según diagnóstico.

Los tumores malignos tienden a mostrar mayor textura media (mayor irregularidad superficial del núcleo) que los benignos, aunque la separación entre grupos es moderada. Ambas distribuciones se superponen considerablemente en el rango 15–25. La textura es útil como variable complementaria, pero su valor discriminativo individual es menor que el de las variables de forma y concavidad.

Suavidad y Simetría

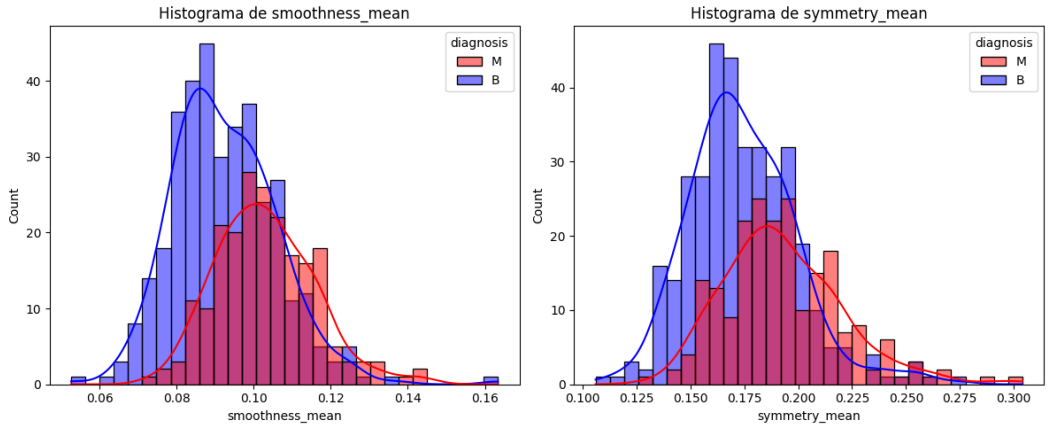

Figura 6: Histogramas de `smoothness_mean` y `symmetry_mean` según diagnóstico.

Ambas variables presentan las diferencias más pequeñas entre grupos malignos y benignos.

En cuanto a la **suavidad**, los casos malignos se desplazan ligeramente hacia valores más altos (mayor irregularidad del contorno), pero la superposición entre distribuciones es sustancial. El pico benigno se ubica cerca de 0.085 y el maligno alrededor de 0.10, con importante traslape en el rango intermedio.

La **simetría** presenta la peor capacidad discriminativa del conjunto: las distribuciones de ambos grupos son prácticamente superponibles en el rango 0.15–0.20, con la única diferencia de que los casos malignos muestran una cola más larga hacia valores altos. Individualmente, esta variable aporta muy poco al diagnóstico diferencial; su utilidad es exclusivamente complementaria en análisis multivariables.

Relaciones entre Variables

Matriz de correlación

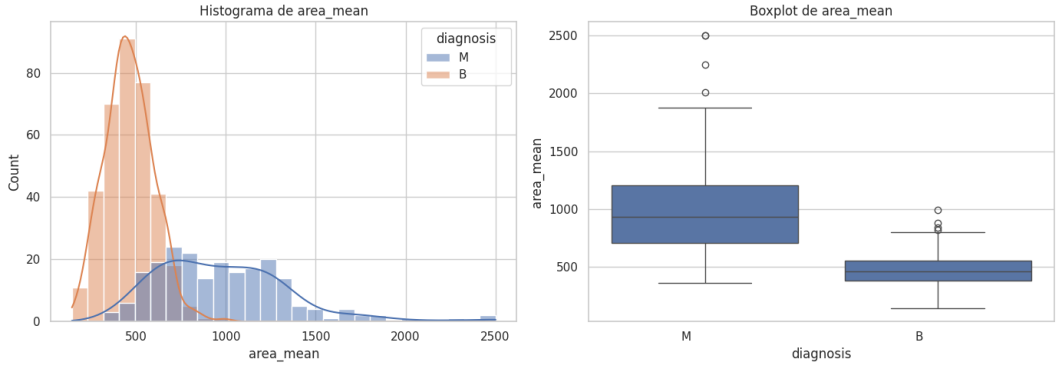

Figura 7: Matriz de correlación de las variables `_mean`.

La matriz de correlación revela la estructura de relaciones entre variables, lo que tiene implicaciones tanto clínicas como para el diseño de modelos predictivos:

Par de variables	r	Interpretación
concavity ↔ concave points	0.92	Miden aspectos muy similares del contorno
concavity ↔ compactness	0.88	Formas irregulares implican mayor concavidad
area ↔ concave points	0.82	Núcleos más grandes tienden a más concavidades
smoothness ↔ compactness	0.66	Irregularidad de contorno y suavidad relacionadas
area ↔ fractal_dimension	-0.28	Núcleos más grandes tienen menor dimensión fractal

Cuadro 2: Correlaciones más relevantes entre variables medias.

Las correlaciones más altas se observan entre variables del mismo grupo conceptual (concavidad, puntos cóncavos, compacidad). Esto significa que estas variables son *redundantes en parte*: miden aspectos distintos pero relacionados del mismo fenómeno morfológico. Al construir un modelo diagnóstico, esta redundancia puede simplificarse sin perder información relevante.

Dispersión: área vs. variables de forma

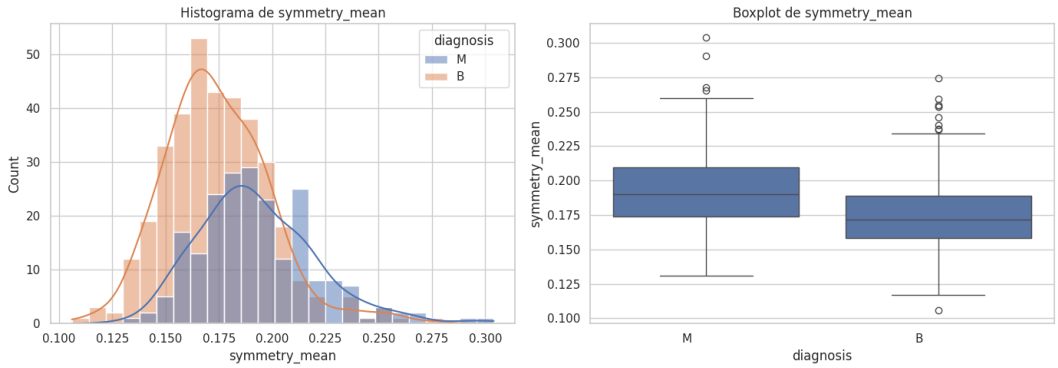

Figura 8: Scatterplot de `area_mean` vs. `concave points_mean`.

El diagrama de dispersión entre área y puntos cóncavos (Figura 8) ofrece la separación visual más clara del dataset: los casos benignos se concentran en la región de bajo área y baja concavidad (cuadrante inferior izquierdo), mientras que los malignos se distribuyen ampliamente hacia valores altos en ambos ejes. Esta combinación de dos variables permite una separación casi completa entre grupos, lo que la hace especialmente

informativa.

Visión global: gráfico de pares

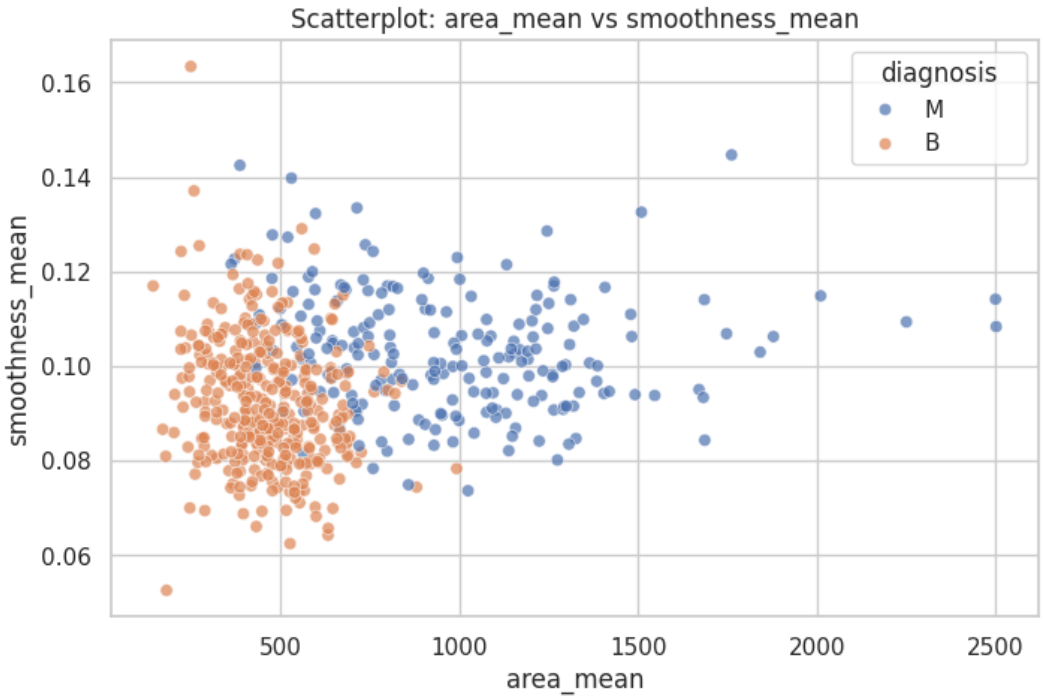

Figura 9: Gráfico de pares (pairplot) de todas las variables medias.

El pairplot confirma de manera global todos los hallazgos anteriores. Las distribuciones en la diagonal muestran que `area_mean`, `concave points_mean`, `concavity_mean` y `compactness_mean` son las variables con mayor separación entre grupos. La textura y la suavidad muestran separación moderada, y la simetría junto con la dimensión fractal presentan distribuciones casi idénticas entre ambos diagnósticos.

Resumen y Conclusiones

Capacidad discriminativa por variable

Capacidad	Variables	Observación
Alta	area, concave points, concavity, compactness	Separación clara entre grupos; son las más útiles para distinguir M de B.
Moderada	texture, smoothness	Contribución útil en análisis combinado; por sí solas son insuficientes.
Baja	symmetry, fractal_dimension	Distribuciones casi superponibles; poco valor diagnóstico individual.

Cuadro 3: Clasificación de variables según su capacidad discriminativa.

Hallazgos principales

1. Los tumores malignos presentan núcleos significativamente más grandes, con medianas de `area_mean` aproximadamente el doble que los benignos.

2. La presencia de puntos cóncavos y concavidades en el contorno nuclear es el hallazgo morfológico con mayor diferencia entre grupos, coherente con el criterio histológico de pleomorfismo nuclear.

3. La compacidad elevada en tumores malignos refleja núcleos de forma irregular, otro hallazgo clásico de malignidad en citopatología.

4. Existen correlaciones muy altas entre concavidad, puntos cóncavos y compacidad, lo que indica que estas variables miden aspectos relacionados del mismo fenómeno

morfológico. En un modelo predictivo, no es necesario incluirlas todas.

5. La combinación de `area_mean` y `concave points_mean` ofrece la mejor separación visual entre grupos y constituye el par de variables más informativo del dataset.

6. La simetría media y la dimensión fractal tienen escaso valor discriminativo individual; su inclusión en análisis debe evaluarse en contexto multivariable.

Nota clínica

Los patrones identificados en este informe son consistentes con criterios morfológicos conocidos en citopatología. Sin embargo, los hallazgos estadísticos presentados **no constituyen criterios diagnósticos definitivos**. Toda decisión clínica debe integrarse con el contexto clínico completo, el criterio del especialista y los protocolos institucionales vigentes.

Glosario

FNA (*Fine Needle Aspiration*) Aspirado con aguja fina: procedimiento diagnóstico para extraer células de una masa mamaria para su análisis morfológico.

Textura Variación en los niveles de gris de la imagen digitalizada del núcleo; refleja la irregularidad de su superficie.

Suavidad Variación local en la longitud de los radios del núcleo celular.

Compacidad Calculada como $(\text{perímetro}^2/\text{área}) - 1$; mide la irregularidad de la forma del núcleo.

Concavidad Severidad de las porciones cóncavas del contorno del núcleo celular.

Puntos cóncavos Número de segmentos cóncavos identificados en el contorno nuclear.

Dimensión fractal Medida de la complejidad del contorno celular; se aproxima mediante el método de la línea de costa (*coastline approximation*).

Boxplot Diagrama de caja que muestra la mediana, el rango intercuartílico y los valores atípicos de una variable.

Correlación Medida estadística de la relación lineal entre dos variables (rango: -1 a 1). Valores cercanos a ± 1 indican fuerte asociación.

Pairplot Gráfico de pares que muestra simultáneamente todas las relaciones bivariadas entre variables de un dataset.

Pleomorfismo nuclear Variabilidad en el tamaño y la forma de los núcleos celulares; criterio morfológico clásico de malignidad en citopatología.

Conclusión del EDA

El análisis exploratorio muestra que las variables más relevantes para diferenciar entre diagnóstico benigno y maligno son aquellas asociadas al tamaño y a la irregularidad de la masa, en especial `area_mean`, `concavity_mean` y `concave points_mean`. También se confirma la existencia de correlaciones fuertes entre algunas variables, lo que sugiere redundancia parcial en el conjunto de datos.

Por esta razón, en etapas posteriores del proyecto se recomienda:

- priorizar variables con mayor capacidad de separación entre clases;
- revisar la multicolinealidad entre variables altamente correlacionadas;
- considerar técnicas de selección de características;
- tener en cuenta el desbalance entre clases al construir modelos.

Interpretación

En esta sección se sintetizan los hallazgos principales del análisis exploratorio, traduciéndolos en información útil para el contexto clínico.

Patrones encontrados

El análisis reveló que el tamaño del tumor (como `area_mean`) no es la única medida determinante. Existe un patrón subyacente donde las características de forma, particularmente la irregularidad de los bordes (`concavity_mean` y `concave points_mean`), exhiben diferencias marcadas entre los tejidos benignos y malignos. Los tumores malignos tienden a presentar células con áreas más grandes y contornos más dentados.

Variables de mayor influencia

Las variables que presentan la mayor separación visual entre diagnósticos, respaldadas por una alta correlación positiva entre sí, son aquellas vinculadas al tamaño y a la concavidad de la masa tumoral. Aquellas medidas enfocadas en la textura o simetría evidenciaron una mayor superposición de datos y menor poder de discriminación individual, lo cual reduce su prioridad frente a las variables de forma pura.

Conclusiones y toma de decisiones

A nivel clínico, los datos confirman que una combinación de inspección morfológica (tamaño e irregularidades del perímetro) permite establecer una predicción considerablemente acertada de la malignidad. Estos resultados sugieren que el equipo oncológico puede apoyarse en un modelo predictivo basado primordialmente en estas medidas clave para clasificar y dar prioridad al tratamiento de los pacientes de alto riesgo.

Siguientes pasos

El hallazgo más importante radica en que no basta con una sola variable para obtener un diagnóstico definitivo. Dado el grado de interrelación (multicolinealidad) encontrado, el paso natural a seguir es la construcción de un modelo de aprendizaje automático supervisado (como Regresión Logística, Random Forest o un Support Vector Machine), considerando previamente una etapa de reducción de características (por ejemplo, Análisis de Componentes Principales - PCA) que consolide las variables correlacionadas en menos componentes sin perder información diagnóstica crítica.